



- **Ders/Dönem:** FET312 Derin Öğrenme / 2025 Güz Dönemi.
  - **Proje Başlığı:** Internet Firewall Traffic Classification using Deep Learning
  - **Ekip Bilgileri:** Ala Buveidani 24040301051  
[alabuveidani@stu.topkapi.tr](mailto:alabuveidani@stu.topkapi.tr)
- Grup İsmi: [NeuralWall](#)
- **GitHub/Repo Bağlantısı:**  
<https://github.com/AlaBuveidani/NeuralWall>.

## 1. Proje Özeti (Abstract)

Bu projede, ağ trafiği verilerinin sınıflandırılması amacıyla derin öğrenme tabanlı modeller kullanılmıştır. Çalışmada UCI Machine Learning Repository tarafından sağlanan *Internet Firewall Data* veri seti kullanılmıştır. Veri seti, firewall tarafından gözlemlenen ağ trafiği akışlarını temsil eden sayısal özelliklerden oluşmaktadır. Çok sınıflı bir sınıflandırma problemi olarak ele alınan çalışmada CNN ve GRU tabanlı modeller geliştirilmiş ve performansları karşılaştırılmıştır. Elde edilen sonuçlar, GRU modelinin yüksek doğruluk ve kararlılık ile firewall kararlarını başarıyla sınıflandırabildiğini göstermektedir.

## 2. Veri Seti Hakkında

**Veri Seti Adı:** Internet Firewall Data

**Kaynak:** UCI Machine Learning Repository

**Link:** <https://archive.ics.uci.edu/dataset/542/internet+firewall+data>

## 2.1 Veri Seti Özellikleri

- Toplam örnek sayısı: **65,532**
- Özellik sayısı: **11 (tamamı sayısal)**
- Problem türü: **Çok sınıflı sınıflandırma**
- Hedef değişken: **Firewall Action** (Allow, Deny, Drop, Reset vb.)
- Veri seti, gerçek dünya firewall trafiğini temsil edecek şekilde dengesiz sınıf dağılımına sahiptir ve bu durum problemi daha gerçekçi hale getirmektedir.

## 3. Veri Ön İşleme (Pre-processing)

- Projede aşağıdaki ön işleme adımları uygulanmıştır:
- Eksik veri kontrolü
- Özelliklerin **StandardScaler** ile normalize edilmesi
- Hedef değişkenin **Label Encoding** yöntemi ile sayısallaştırılması
- Derin öğrenme modelleri için verinin (örnek, özellik, kanal) formatına dönüştürülmesi
- Bu işlemlerden sonra veri seti model eğitime hazır hale getirilmiştir.

## 4. Kullanılan Modeller

### 4.1 Convolutional Neural Network (CNN)

CNN modeli, özellikler arasındaki lokal ilişkileri öğrenmek amacıyla kullanılmıştır. Model, Conv1D ve MaxPooling katmanlarından oluşmaktadır.

### 4.2 Gated Recurrent Unit (GRU)

GRU modeli, özellikler arasındaki ardışık bağımlılıkları yakalayabilmek için tercih edilmiştir. GRU, LSTM'e göre daha az parametreye sahip olup daha hızlı öğrenme sağlamaktadır.

## 5. Model Eğitimi

- Epoch sayısı: **20**
- Batch size: **64**
- Optimizer: **Adam**
- Kayıp fonksiyonu: **Sparse Categorical Crossentropy**
- Eğitim/Doğrulama oranı: **%80 / %20**

- GRU modeli eğitim sürecinde hızlı yakınsama göstermiştir.

## 6. Performans Değerlendirmesi

### 6.1 Kullanılan Metrikler

- Accuracy
- Precision
- Recall
- F1-score
- Confusion Matrix

### 6.2 GRU Model Sonuçları

- Eğitim doğruluğu:  $\approx 99.5\%$
- Kayıp değeri:  $\approx 0.02$
- Confusion Matrix sonuçları, sınıfların büyük çoğunluğunun doğru tahmin edildiğini ve modelin yüksek ayırt ediciliğe sahip olduğunu göstermektedir.

## 7. Model Karşılaştırması

Model	Accuracy	Eğitim Süresi	Genel Performans
CNN	Yüksek	Orta	İyi
GRU	Çok Yüksek	Daha Kısa	En İyi

- GRU modeli hem doğruluk hem de kararlılık açısından CNN modeline üstünlük sağlamıştır.

## 8. Sonuç (Conclusion)

Bu çalışmada, firewall trafiği sınıflandırması problemi için derin öğrenme tabanlı modeller başarıyla uygulanmıştır. Özellikle GRU modeli, yüksek doğruluk oranı ve düşük hata değeri ile en iyi performansı göstermiştir. Elde edilen sonuçlar, GRU tabanlı modellerin ağ güvenliği ve intrusion detection sistemleri için etkili bir çözüm sunduğunu ortaya koymaktadır.

## 9. Kaynakça

- UCI Machine Learning Repository, *Internet Firewall Data*.
- Goodfellow, I., Bengio, Y., Courville, A., *Deep Learning*, MIT Press.
- Hochreiter, S., Schmidhuber, J., Long Short-Term Memory.
- Cho, K. et al., Learning Phrase Representations using GRU.
- Scikit-learn Documentation – Model Evaluation Metrics.